Projet entrepôt de données

Seattle Airbnb Open Data

Boursier Louis, Filaudeau Eloi, Lasherme Loïc, Nantier Matthias

https://github.com/loutouk/AirBnbDataWareHouse?fbclid=IwAR2pvwhMl38kLbcfEZWgI1Re0pcp3exHfyEBntjkolrTxXu8RAZyu1OxdeM

Table des matières

1 Introduction

Le but de ce projet était l'intégration de données dans un entrepôt de données. Pour cela nous devions trouver un exemple concret qui se rapproche de la réalité. Nous avons donc optés pour un exemple qui est : "les Airbnb de Seattle". Notre jeu de données provient du site web Kaggle qui est fournit directement par Airbnb sous une une licence CC0 : Public Domain.

Contenu :

- Les logements avec leurs propriétaires.
- Les avis des utilisateurs sur leurs réservations.
- Les calendriers, c'est à dire les dates associées aux réservations à un certain prix, et leur disponibilité à cette date.

Idées :

- Décrire les caractéristiques de chaque quartier de Seattle en utilisant la description des logements.
- Quelles sont les plus forts moments d'affluence ? Comment les prix varient ?
- Quelle est la tendance vis à vis des visiteurs à Seattle et des logements proposés ?

Après avoir trouvé nos données, il a fallut les transformer, les nettoyer pour enfin faire nos requêtes dessus. Nous avons donc opté pour un schéma en étoile et de travailler avec MySQL 5.7, car impossible de travailler sous Oracle chez nous, `https://livesql.oracle.com/` est beaucoup trop lent, ne peut pas faire l'importation de fichier supérieur à 1Mb, et les sessions ont une durée limitée dans le temps.

2 Conception de l'entrepôt

Pour créer notre entrepôt avec le jeu de données, nous avons dû réaliser plusieurs opérations. La première consistait à décomposer le jeu en plusieurs table afin de créer notre schéma en étoile. Ensuite nous avons dû nettoyer plusieurs fois les données, ce qui n'était pas chose aisée.

2.1 Transformation des données

1. Créer une dimension date
   i. Créer un nouveau projet OpenRefine à partir du fichier `calendar.csv`. Pour accélérer la vitesse des opérations, on peut ne charger qu'une partie des données `Load at most 100000 row(s) of data`
   ii. Sous OpenRefine, créer une nouvelle colonne `year` depuis la colonne `date`. `Edit column > Add column based on this colulmn > split(value, "-")[0]`
   iii. Faire la même chose pour les mois et les jours
   iv. Créer la clé dateId pour notre nouvelle table à partir de la colonne `calendar`. Sa valeur est optenue avec l'expression suivante :
   `sha1(cells.year.value+cells.month.value+cells.day.value).substring(0,10)`
   v. Supprimer les colonnes `date, available, price, listing_id` qui ne sont plus utiles `Edit column > Remove this column`
   vi. Pour chaque table des dimensions, on enlève les duplicats, c'est à dire que chaque ligne doit être unique (2FN). Voir l'annexe `Removing duplicates` plus bas
   vii. On peut maintenant exporter ce projet en csv, pour récupérer notre dimension date
2. Créer une dimension localisation
   i. Créer un nouveau projet OpenRefine à partir du fichier `listings.csv`
   ii. Ne garder que les colonnes `neighbourhood_cleansed, neighbourhood_group_cleansed` et `zipcode`

iii. Créer la clé localisationId pour notre nouvelle table à partir de nos trois colonnes. Sa valeur est optenue avec l'expression suivante : `sha1(value + row.cells.zipcode.value + row.cells.neighbourhood_group_cleansed.value).substring(0,10)`

iv. Comme avant, éliminer les duplicats

v. Exporter ce projet en csv pour récupérer la dimension localisation

3. Créer une dimension propriétaire
   i. Créer un nouveau projet OpenRefine à partir du fichier `listings.csv`
   ii. Ne garder que les colonnes `host_id, host_name, host_since, host_response_time, host_response_rate, host_acceptance_rate, host_is_superhost`
   iii. Renommer la clé `host_id` en `proprietaireId`
   iv. Comme avant, éliminer les duplicats sur `proprietaireId`
   v. Exporter ce projet en csv pour récupérer la dimension propriétaire
4. Créer une dimension logement
   i. Créer un nouveau projet OpenRefine à partir du fichier `listings.csv`
   ii. Ne garder que les colonnes `name, summary, space, description`
   iii. réer la clé `logementId` pour notre nouvelle table à partir de la colonne `name`. Sa valeur est optenue avec l'expression suivante : `sha1(value).substring(0,10)`
   iv. Comme avant, éliminer les duplicats sur `logementId`
   v. Exporter ce projet en csv pour récupérer la dimension logement
5. Créer la première partie de la table des faits
   i. Créer un nouveau projet OpenRefine à partir du fichier `listings.csv`
   ii. Ne garder que les colonnes `id, host_id, name, neighbourhood_cleansed, neighbourhood_group_cleansed` et `zipcode`
   iii. Recréer les colonnes correspondant aux clés des tables des dimensions à partir des colonnes gardées, comme fait dans les étapes précédentes
   iv. Supprimer les colonnes gardées pour ne laisser que les colonnes générées correspondants aux clés des tables des dimensions en gardant la colonne `id` pour plus tard
   v. Exporter en csv
6. Créer la deuxième partie de la table des faits
   i. Créer un nouveau projet OpenRefine à partir du fichier `calendar.csv`
   ii. Recréer la colonne `dateId` à partir de la colonne `date`, comme avant, puis la supprimer la colonne `date`
   iii. L'étape précédente est ralisée avec la commnade GREL suivante : `sha1(split(value, "-")[0] + split(value, "-")[1] + split(value, "-")[2]).substring(0,10)`
   iv. Exporter en csv
7. Fusionner les deux tables des faits en une seule avec une jointure sur `listing_id / id`
   i. Ouvrir le projet de la deuxième partie de la table des faits sous OpenRefine (celle qui contient le plus d'enregistrements)
   ii. Sur la colonne `listing_id`, cliquer sur `Edit column > Add column based on this column` 3. Joindre la colonne `logementId` de l'autre projet à notre projet avec l'expression : `cell.cross("projetTableFaitsUne", "id").cells["logementId"].value[0]`
   iii. Même chose avec la colonne `proprietaireId` et `localisationId`
   iv. Supprimer la colonne `listing_id`
   v. Ne garder que la table des faits courante comme table des faits
   vi. Exporter en csv

Une fois cela fait, nous avons transformé nos fichiers csv en un fichier sql à l'aide de l'outil en ligne `http://www.convertcsv.com/csv-to-sql.htm` car l'importation de fichier csv sur `https://livesql.oracle.com/` n'est pas disponible.

2.2 Nettoyage des données

Une fois les tables créées, il nou a fallut les nettoyer au mieux. Pour cela nous avons eu recours à OpenRefine mais pas que. Voici les étapes réalisées :

1. Enlever les valeurs nulles sous OpenRefine `Facet > Customized Facet > Facet by blank` puis cliquer sur `All > Edit rows > Remove all matching rows`
2. Enlever les valeurs erronées en les repérant avec le `Facet > Text Facet` pour les chaînes de caractères, et `Facet > Numeric Facet` pour les nombres, les enlever comme expliquer ci-dessus
3. Enlever les caractères non ASCII qui provoquait une erreur lorsque l'on travaillait avec `https://livesql.oracle.com/`. Pour cela nous avons eu recours à une commande perl : `perl -pi -e 's/[^[:ascii:]]//g' fichier_a_transformer`.

2.3 Schéma en étoile de l'entrepôt

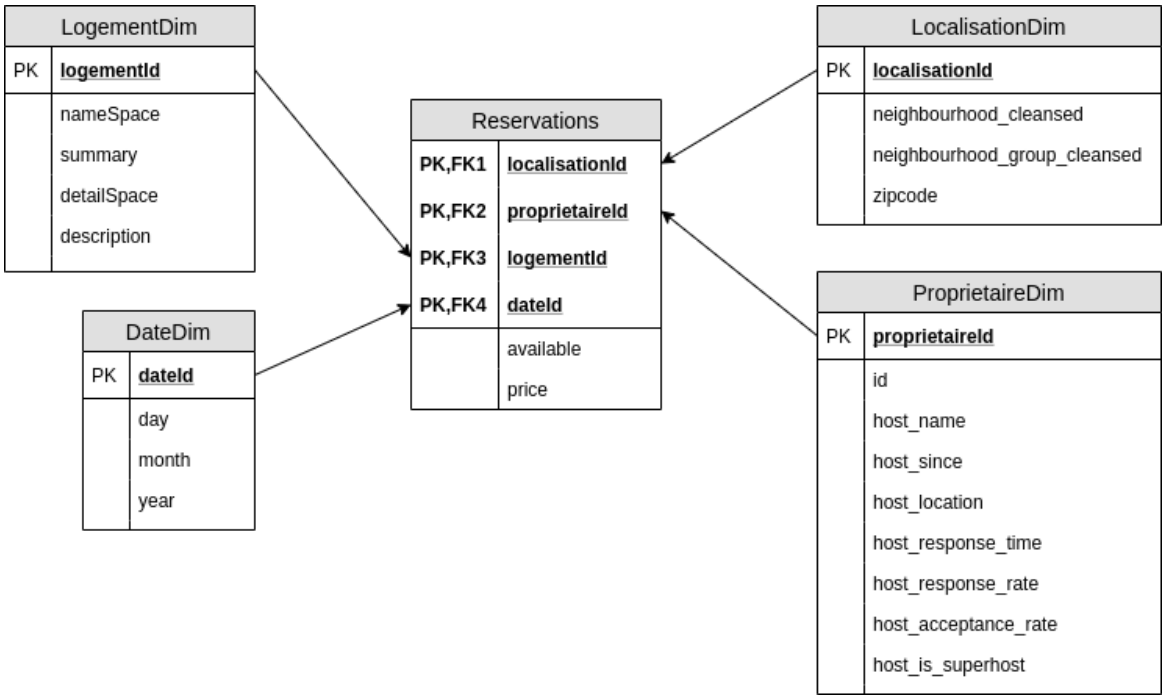

3 Opérations sur l'entrepôt

3.1 Requêtes :

Voici les requêtes que nous avons réalisés sur notre entrepôt — elles peuvent être exécutées via le fichier `projet.sql` en annexe du rapport :

- Requête n°1 : Permet d'obtenir le nombre de logements différents par années et au totale.

```
SELECT year, count(DISTINCT logementId)
FROM DateDim NATURAL JOIN LogementDim NATURAL JOIN Reservations
GROUP BY year WITH ROLLUP;
```

- Requête n°2 : Permet d'obtenir le nombre de logement par code postal, par an et totale.

```
SELECT zipcode, year, count(DISTINCT logementId)
FROM DateDim NATURAL JOIN LocalisationDim NATURAL JOIN LogementDim
    NATURAL JOIN Reservations
GROUP BY zipcode, year WITH ROLLUP;
```

- Requête n°3 : Permet d'obtenir le prix que peut gagner chaque région, par mois, par années et au totale.

```
SELECT zipcode, year, month, SUM(price)
FROM DateDim NATURAL JOIN LocalisationDim NATURAL JOIN Reservations
WHERE available = 't'
GROUP BY zipcode, year, month WITH ROLLUP;
```

- Requête n°4 : Permet d'obtenir le prix moyen par an, par région et au total.

```
SELECT zipcode, year, avg(price)
FROM DateDim NATURAL JOIN LocalisationDim NATURAL JOIN Reservations
WHERE price IS NOT NULL
GROUP BY zipcode, year WITH ROLLUP;
```

- Requête n°5 : Permet d'obtenir le rang des 20 personnes qui gagne le plus.

```
SET @curRank := 0;
SELECT *, @curRank := @curRank + 1 AS rank FROM (
    SELECT proprietaireId, host_name, year, SUM(price)
    FROM DateDim NATURAL JOIN LocalisationDim NATURAL JOIN ProprietaireDim
        NATURAL JOIN Reservations
    GROUP BY proprietaireId, year
    ORDER BY SUM(price) DESC
) AS t LIMIT 20;
```

- Requête n°6 : Permet d'afficher le nombre de proprietaire par région et au total.

```
SELECT zipcode, count(DISTINCT proprietaireId)
FROM LocalisationDim NATURAL JOIN ProprietaireDim NATURAL JOIN Reservations
GROUP BY zipcode WITH ROLLUP;
```

- Requête n°7 : Permet d'obtenir le nombre de fois qu'un propriétaire a obtenu le titre de superhost par région et au total.

```
SELECT zipcode, count(proprietaireId)
FROM LocalisationDim NATURAL JOIN ProprietaireDim NATURAL JOIN Reservations
WHERE host_is_superhost = 't'
GROUP BY zipcode WITH ROLLUP;
```

- Requête n°8 : Permet d'afficher le nombre de response_rate de chaque hote, et le nombre total.

```
SELECT host_name, host_response_rate, count(*)
FROM ProprietaireDim NATURAL JOIN Reservations
WHERE host_response_rate IS NOT NULL
GROUP BY host_response_rate, host_name WITH ROLLUP;
```

3.2 Résultats :

Voici les résultats de nos requêtes précédentes — pour obtenir la totalité de celles-ci, vous pouvez aller voir dans le fichier annexe `result.txt` :

- Résultats n°1 :

year	count(DISTINCT logementId)
2016	270
2017	269
NULL	270

- Résultats n°2 :

zipcode	year	count(DISTINCT logementId)
98107	2016	128
98107	2017	128
98107	NULL	128
98109	2016	74
98109	2017	73
98109	NULL	74
98117	2016	4
98117	2017	4
98117	NULL	4
98119	2016	64
98119	2017	64
98119	NULL	64
NULL	NULL	270

- Résultats n°3 :

zipcode	year	month	SUM(price)
98107	2016	1	198981
98107	2016	2	255808
98107	2016	3	314406
98107	2016	4	299849
98107	2016	5	319755
98107	2016	6	374994
98107	2016	7	331889
98107	2016	8	354556
98107	2016	9	328862
98107	2016	10	343146
98107	2016	11	334926
98107	2016	12	368250
98107	2016	NULL	3825422
98107	2017	1	23901
98107	2017	NULL	23901
98107	NULL	NULL	3849323
98109	2016	1	209538
98109	2016	2	249775

etc...

- Résultats n°4 :

zipcode	year	AVG(price)
98107	2016	125.09964354622453
98107	2017	127.13297872340425
98107	NULL	125.11206812493906
98109	2016	169.36099685458504
98109	2017	163.74257425742573
98109	NULL	169.32688029820238
98117	2016	109.7921568627451
98117	2017	147.5
98117	NULL	110.23062015503876
98119	2016	199.1352493660186
98119	2017	213.37037037037038
98119	NULL	199.23451927423
NULL	NULL	154.69553491159724

- Résultats n°5 :

proprietaireId	host_name	year	SUM(price)	rank
32713558	Kary	2016	249900	1
22372266	Sarah	2016	218018	2
919364	Jeff	2016	217800	3
16708587	Jill	2016	205848	4
28770702	Mercy	2016	186119	5
24049136	Jeff	2016	178642	6
430709	Sea To Sky Rentals	2016	173015	7
1452570	Emily	2016	168000	8
3792761	Kimberly	2016	165790	9
6407320	Varun	2016	163460	10
5177328	Andrea	2016	163354	11
23669617	Irmela	2016	145200	12
24633415	David	2016	145183	13
2231298	Chris	2016	136647	14
33147763	Tracy	2016	126000	15
12867960	Maureen	2016	122337	16
19993125	Steven	2016	122020	17
6097842	Brittain	2016	118615	18
33225983	Jean	2016	117047	19
31148752	Bo	2016	108658	20

- Résultats n°6 :

zipcode	count(DISTINCT proprietaireId)
98107	110
98109	67
98117	4
98119	56
NULL	233

- Résultats n°7 :

zipcode	count(proprietaireId)
98107	13870
98109	6014
98117	365
98119	4745
NULL	24994

- Résultats n°8 :

host_name	host_response_rate	count(*)
Alan	100%	365
Alan & Katence	100%	365
Alex	100%	730
Alexis	100%	365
Alianna	100%	365
Aman	100%	365
Amber	100%	365
Amelia & Foxy	100%	365
Andrea	100%	730
Andrew	100%	365
Anisa	100%	365
Annie	100%	730
Audrey	100%	365
Barbara	100%	730
Barrie	100%	365
Bill	100%	365
Bob	100%	730
Brad & Liz	100%	730
Brian	100%	730
Brittain	100%	730

etc...

4 Conclusion

Le fait de devoir concevoir un entrepôt n'est pas chose si facile. En effet, il d'abord réussir à trouver le bon jeu de données avec les bonnes licences. Ensuite, il faut créer notre entrepôt avec le schéma en étoile. Arrive la tâche la plus éprouvante et la moins intéressante qui est le nettoyage des données. Cela est extrêment chronophage car en général, les données brutes ne sont jamais homogène. Et pour finir arrive l'étape des requêtes.

Au cours de ce projet, nous nous sommes heurté à plusieurs problèmes. Nous avons d'abord changé 3 fois de dataset. En effet, les deux premiers n'étaient pas si intéressant après consultation, mais aussi beaucoup de données manquantes. Ensuite, le nettoyage de données posa problème. Le fait que `https://livesql.oracle.com/` n'acceptait pas les caractères non ASCII n'était pas facile à repérer. En effet, quand nous essayions d'insérer nos tables dedans, lorsqu'une erreur apparaissait, nous n'avions aucun log de nos erreurs. Il était seulement affiché erreur en gros. Pour finir, `https://livesql.oracle.com/` posant énormement de problèmes, car n'acceptait que des fichiers pesant moins de 1Mb, nous avons décidé de passer sous MySQL, limitant nos possibilités de requêtes.